

UNIVERSIDADE DE MARÍLIA - UNIMAR

Análise e Desenvolvimento de Sistemas

CLASSIFICAÇÃO DA QUALIDADE DE VINHOS TINTOS

Projeto Avaliativo P2
Machine Learning - Teoria e Aplicado

Integrantes

Carlos Henrique Legutcke Filho - RA 1988772

José Henrique de Castro Fernandes - RA 1994033

Leonardo dos Santos da Silva - RA 2034122

Marília - SP
2026

Resumo

Este relatório apresenta a versão final do projeto de classificação da qualidade de vinhos tintos por meio de propriedades físico-químicas. O problema foi definido como classificação binária: vinhos com nota maior ou igual a 7 pertencem à classe “Bom”, enquanto as demais notas formam a classe “Ruim/Médio”. Após inspeção dos dados, 240 registros duplicados foram removidos, restando 1.359 amostras. Foram comparados K-Nearest Neighbors, Support Vector Classifier e Random Forest por meio de validação cruzada estratificada e de um conjunto de validação independente. O SVC foi selecionado pelo maior F1-score na validação e obteve, no teste final, acurácia de 0,805, recall de 0,784, F1-score de 0,523 e ROC-AUC de 0,884. O modelo foi salvo e integrado a uma aplicação Streamlit capaz de receber os atributos químicos e apresentar classe e probabilidade estimadas.

Palavras-chave: aprendizado de máquina; classificação; vinho; SVC; Streamlit; dados desbalanceados.

1. Introdução

A avaliação da qualidade de vinhos é tradicionalmente realizada por análise sensorial. Embora indispensável, esse processo envolve subjetividade e exige avaliadores especializados. Dados laboratoriais oferecem uma fonte complementar de informação, pois propriedades como teor alcoólico, acidez, sulfatos, densidade e pH podem ser mensuradas de maneira objetiva.

O objetivo deste projeto é desenvolver um fluxo reproduzível de Machine Learning para auxiliar a triagem de vinhos tintos. A versão final foi revisada para garantir coerência entre notebook, métricas, modelo salvo e aplicação. As principais correções incluem análise de duplicatas, uso efetivo da validação, prevenção de vazamento de dados com Pipeline e preservação do teste para uma única avaliação final.

2. Conjunto de dados e definição do problema

Foi utilizado o conjunto Wine Quality, disponibilizado pelo UCI Machine Learning Repository, em sua versão referente a vinhos tintos Vinho Verde. O arquivo contém 11 variáveis físico-químicas de entrada e a variável quality, correspondente à nota atribuída ao vinho.

Característica	Resultado
Registros originais	1.599
Variáveis de entrada	11
Valores ausentes	0
Linhas duplicadas	240
Registros após limpeza	1.359
Classe positiva	quality $\geq$ 7
Vinhos bons após limpeza	184 (13,54%)

A classe positiva representa somente 13,54% das amostras tratadas. Portanto, o conjunto é desbalanceado e a acurácia isolada poderia favorecer classificadores que priorizassem a classe majoritária.




Figura 1 - Distribuição da classe-alvo após a remoção de duplicatas. Fonte: elaboração própria.

3. Análise exploratória e qualidade dos dados

A inspeção inicial foi realizada com os métodos `head()`, `info()` e `describe()`. Todas as colunas apresentaram tipos numéricos compatíveis e não foram identificados valores ausentes. Foram encontradas 240 linhas exatamente duplicadas, removidas antes da divisão dos dados para evitar que a mesma observação aparecesse em treino e teste.

Os possíveis outliers foram identificados pelo intervalo interquartil (IQR) e visualizados em boxplots. Diferentemente da versão anterior, eles não foram excluídos automaticamente. Valores extremos podem representar medições químicas válidas; além disso, a remoção reduziria ainda mais a classe minoritária. Caso fosse necessário aplicar uma transformação, seus parâmetros deveriam ser aprendidos exclusivamente no treino.

O mapa de correlação mostrou que teor alcoólico e sulfatos apresentam associação positiva com a qualidade, enquanto a acidez volátil apresenta associação negativa. Essas relações são descritivas e não devem ser interpretadas como causalidade.

4. Pré-processamento e divisão dos dados

A variável-alvo foi criada atribuindo classe 1 aos vinhos com nota maior ou igual a 7. Em seguida, os dados foram separados de forma estratificada, preservando a proporção de aproximadamente 13,6% de vinhos bons em cada subconjunto.

Conjunto	Amostras	Percentual	Classe positiva
Treino	815	60%	13,5%
Validação	272	20%	13,6%
Teste	272	20%	13,6%

O `StandardScaler` foi incluído no mesmo Pipeline de cada classificador. Dessa forma, em cada fold da validação cruzada, a média e o desvio padrão são aprendidos somente com a parcela de treino daquele fold. Essa estrutura elimina o vazamento de informações existente quando a padronização é ajustada antes da validação cruzada.

5. Modelos e estratégia de avaliação

Foram treinados KNN, SVC e Random Forest. O KNN utilizou cinco vizinhos e pesos baseados na distância. O SVC foi configurado com geração de probabilidades e `class_weight='balanced'`. A Random Forest utilizou 300 árvores e o mesmo balanceamento de classes. O parâmetro de balanceamento aumenta a penalização por erros na classe minoritária.

A validação cruzada utilizou StratifiedKFold com cinco folds, embaralhamento e `random_state` igual a 42. Foram avaliadas acurácia, precisão, recall, F1-score e ROC-AUC. O F1-score foi adotado como critério principal, com ROC-AUC e recall para desempate.

5.1 Resultados da validação cruzada

Modelo	Acurácia	Precisão	Recall	F1	ROC-AUC
SVC	0,815	0,401	0,745	0,521	0,870
Random Forest	0,861	0,489	0,491	0,488	0,868
KNN	0,863	0,506	0,336	0,400	0,792

Na validação cruzada, o SVC apresentou o maior F1-score e o maior recall. Random Forest e KNN obtiveram acurácia mais alta, porém encontraram uma parcela menor dos vinhos bons.

6. Comparação no conjunto de validação

Após a validação cruzada, cada candidato foi ajustado somente no conjunto de treino e avaliado nas 272 amostras de validação. Essa etapa foi utilizada para a escolha do modelo. O conjunto de teste permaneceu sem consulta.

Modelo	Acurácia	Precisão	Recall	F1	ROC-AUC
SVC	0,816	0,411	0,811	0,545	0,876
Random Forest	0,860	0,486	0,486	0,486	0,884
KNN	0,868	0,519	0,378	0,438	0,820

O SVC obteve F1-score de 0,545 e recall de 0,811, superando os demais modelos no critério principal. A Random Forest alcançou ROC-AUC ligeiramente superior, mas seu F1-score e recall foram menores. O KNN apresentou a maior precisão, porém identificou somente 37,8% dos vinhos bons.

Matrizes de confusão no conjunto de validação




Figura 2 - Matrizes de confusão dos três modelos no conjunto de validação. Fonte: elaboração própria.




Figura 3 - Curvas ROC comparativas no conjunto de validação. Fonte: elaboração própria.

7. Modelo final e avaliação no teste

O Support Vector Classifier foi escolhido como modelo final. Após a escolha, o Pipeline foi treinado novamente com a união dos conjuntos de treino e validação, totalizando 1.087 amostras. O teste foi consultado uma única vez para estimar a capacidade de generalização.

Métrica	Resultado
Acurácia	0,805
Precisão	0,392
Recall	0,784
F1-score	0,523
ROC-AUC	0,884

A matriz final registrou 190 verdadeiros negativos, 45 falsos positivos, 8 falsos negativos e 29 verdadeiros positivos. Assim, o modelo identificou corretamente 29 dos 37 vinhos bons presentes no teste. O recall de 0,784 mostra que aproximadamente 78,4% da classe positiva foi encontrada.

A precisão de 0,392 indica a presença de falsos positivos: parte dos vinhos previstos como bons pertence à classe ruim/média. Esse comportamento é o custo do maior alcance da classe minoritária e deve ser considerado no uso da aplicação. O ROC-AUC de 0,884 demonstra boa capacidade de ordenação entre casos positivos e negativos em diferentes limiares.




Figura 4 - Matriz de confusão e curva ROC do SVC no conjunto de teste. Fonte: elaboração própria.

8. Importância das variáveis

Como o SVC não oferece uma importância nativa diretamente comparável à Random Forest, foi utilizada importância por permutação. O método embaralha uma variável por vez e mede a redução do F1-score. Álcool e sulfatos apresentaram as maiores contribuições positivas, seguidos pela acidez volátil e pelos cloretos.




Figura 5 - Importância por permutação calculada no teste final. Valores próximos de zero ou negativos indicam baixa contribuição estável nessa amostra. Fonte: elaboração própria.

9. Salvamento do modelo e aplicação Streamlit

O notebook salva o Pipeline completo em `model/pipeline_vinhos_final.pkl`. Para manter compatibilidade e facilitar a inspeção, também são salvos o classificador em `model/modelo_vinhos_final.pkl`, o padronizador em `model/scaler_vinhos.pkl` e os metadados em `model/metadata_modelo.json`. Todos esses arquivos são gerados pelo mesmo treinamento avaliado no teste.

A aplicação Streamlit contém título, 11 campos compatíveis com as variáveis do modelo, botão de predição, organização das entradas em DataFrame, carregamento do Pipeline salvo, execução da

previsão e apresentação da classe e da probabilidade estimada. O app foi testado localmente com exemplos das duas classes.

10. Limitações

- A classe de vinhos bons representa apenas 13,54% dos registros tratados.
- A classificação binária agrupa notas diferentes e simplifica a escala original.
- O dataset contém somente vinhos tintos Vinho Verde de uma origem específica.
- As variáveis não incluem informações como marca, preço, safra ou tipo de uva.
- A precisão da classe positiva é inferior ao recall, indicando falsos positivos.
- A previsão auxilia a triagem, mas não substitui avaliação sensorial especializada.

11. Conclusão

A revisão metodológica tornou o projeto mais organizado, rastreável e coerente. A remoção de duplicatas evitou repetição de observações, o Pipeline impediu vazamento durante a validação cruzada e a utilização efetiva do conjunto de validação permitiu escolher o modelo sem contaminar o teste.

O SVC apresentou o melhor equilíbrio para a classe minoritária e alcançou no teste recall de 0,784, F1-score de 0,523 e ROC-AUC de 0,884. O resultado demonstra que as propriedades físico-químicas possuem informação útil para auxiliar a classificação. Entretanto, os falsos positivos e as limitações do dataset exigem interpretação cuidadosa.

O modelo final está salvo de forma reproduzível e integrado a uma aplicação Streamlit funcional. A coerência entre notebook, arquivos de modelo, relatório e aplicação atende aos objetivos técnicos da etapa P2.

Referências

CORTEZ, P.; CERDEIRA, A.; ALMEIDA, F.; MATOS, T.; REIS, J. Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, v. 47, n. 4, p. 547-553, 2009.

UCI MACHINE LEARNING REPOSITORY. Wine Quality. Disponível em: <https://archive.ics.uci.edu/dataset/186/wine+quality>. DOI: 10.24432/C56S3T.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

STREAMLIT. Streamlit documentation. Disponível em: <https://docs.streamlit.io/>.